


UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN

FACULTAD DE CIENCIAS FÍSICO MATEMÁTICAS



**CARACTERIZACIÓN Y CLASIFICACIÓN AUTOMÁTICA DE VOCES
NARRATIVAS EN DRÁCULA DE BRAM STOKER MEDIANTE
PROCESAMIENTO DE LENGUAJE NATURAL**

Por

ALEJANDRA PAOLA CASTILLO GALLEGOS

Como requisito parcial para obtener el Grado de
MAESTRÍA EN CIENCIA DE DATOS

Agosto, 2026

Universidad Autónoma de Nuevo León
Facultad de Ciencias Físico Matemáticas

Los miembros del Comité de Tesis recomendamos que la Tesina
“Caracterización y clasificación automática de voces narrativas en Drácula de
Bram Stoker mediante procesamiento de lenguaje natural”, realizada por la
alumna Alejandra Paola Castillo Gallegos, con número de matrícula 1801137,
sea aceptada para su defensa como opción al grado de Maestría en Ciencia de
Datos.

El Comité de Tesis

(Título y nombre)
Director

(Título y nombre)
Revisor

(Título y nombre)
Revisor

Vo.Bo.

Dra. Azucena Yoloxóchitl Ríos Mercado
Coordinadora de la Maestría en Ciencia de Datos

San Nicolás de los Garza, N.L.

DEDICATORIA

A toda mi familia, por acompañarme y apoyarme durante este proceso académico; y a mis mentores por orientarme y alentarme hacia el estudio y análisis de obras literarias.

ÍNDICE DE CONTENIDO

Capítulo	Página
1. INTRODUCCIÓN.....	1
1.1 Contexto del estudio	1
1.2 Propuesta de investigación	1
2. DELIMITACIÓN Y PLANTEAMIENTO DEL PROBLEMA DE INVESTIGACIÓN.....	3
2.1 Planteamiento del problema	3
2.2 Delimitación	3
2.3 Alcances y limitaciones	4
3. JUSTIFICACIÓN.....	5
4. FORMULACIÓN DE OBJETIVOS.....	6
4.1 Objetivo general	6
4.2 Objetivos específicos	6
5. MARCO TEÓRICO.....	7
5.1 Humanidades digitales y análisis literario computacional	7
5.2 Procesamiento de lenguaje natural	7
5.3 Estilometría y atribución de autoría	7
5.4 Análisis de sentimientos y emociones	8
5.5 Aprendizaje automático para clasificación de textos	8
5.6 La estructura narrativa de Drácula	8
6. METODOLOGÍA.....	9
6.1 Enfoque y diseño	9
6.2 Fuente de datos y construcción del corpus	9
6.3 Variables	9
6.4 Preprocesamiento	10
6.5 Análisis exploratorio	10
6.6 Modelado	10
6.7 Validación y métricas	10
6.8 Interpretabilidad y análisis de errores	11
6.9 Herramientas y reproducibilidad	11
7. RESULTADOS Y CONCLUSIONES.....	12
7.1 Resultados esperados	12
7.2 Conclusiones preliminares	12
Referencias	13

Anexos	14
--------------	----

AGRADECIMIENTOS

Agradezco a la Universidad Autónoma de Nuevo León y a la Facultad de Ciencias Físico Matemáticas por la formación que eh recibido. Asimismo, agradezco al personal docente de la Maestría en Ciencia de Datos por las herramientas que hicieron posible elaborar este proyecto interdisciplinario.

CAPÍTULO 1

INTRODUCCIÓN

1.1 Contexto del estudio

Hoy en día con la creciente digitalización y el desarrollo de técnicas de procesamiento de lenguaje natural han ampliado las posibilidades para estudiar textos desde una perspectiva cuantitativa. No es muy común debido a la noción de que el arte y la tecnología no se mezclan, pero en este estudio no se pretende que las humanidades digitales sustituyan la interpretación crítica, sino el incorporar métodos computacionales capaces de revelar patrones léxicos, estilísticos, emocionales y estructurales que pueden resultar difíciles de observar mediante una lectura exclusivamente manual.

Dentro de esta área tenemos la estilometría, la cual es una subdisciplina de la estilística que estudia cuantitativamente el estilo de escritura mediante variables como frecuencia de palabras, longitud de oraciones, riqueza léxica, uso de puntuación y secuencias de caracteres o palabras. Estas características pueden emplearse para comparar textos, identificar semejanzas y entrenar modelos de clasificación (Moyano Moreno, 2023).

La novela “Drácula”, publicada por Bram Stoker en 1897, constituye un caso particularmente adecuado para este enfoque. Su narración se construye mediante diarios, cartas, telegramas, recortes periodísticos y otros documentos atribuidos a distintos personajes. Esta estructura epistolar produce múltiples voces narrativas dentro de una misma obra y permite formular una pregunta propia de la Ciencia de Datos: las diferencias entre narradores son suficientemente consistentes para ser identificadas mediante modelos automáticos.

1.2 Propuesta de investigación

La investigación propone construir un corpus estructurado de fragmentos de la novela “Drácula” etiquetados por narrador y aplicar técnicas de procesamiento de lenguaje natural, análisis exploratorio, estilometría y aprendizaje automático supervisado. El propósito principal será caracterizar las voces narrativas y evaluar si un modelo puede predecir quién narra un fragmento sin utilizar explícitamente nombres propios ni marcas editoriales que revelen la respuesta.

Además de la clasificación, se analizarán patrones de sentimientos y emociones para describir la evolución narrativa. Este componente tendrá un carácter complementario y permitirá examinar si los narradores difieren no

solo en su estilo, sino también en la distribución de emociones asociadas con sus intervenciones.

CAPÍTULO 2

DELIMITACIÓN Y PLANTEAMIENTO DEL PROBLEMA DE INVESTIGACIÓN

2.1 Planteamiento del problema

El análisis literario tradicional de una novela epistolar identifica diferencias de perspectiva, tono y construcción de los personajes mediante lectura crítica. Sin embargo, cuando se desea cuantificar esas diferencias aparece un problema metodológico: transformar una noción cualitativa como la voz narrativa en variables observables y comparables.

En “Drácula” existen narradores con cantidades desiguales de texto. Algunos personajes producen numerosas entradas de diario, mientras otros aparecen en pocas cartas o documentos. Esta desigualdad puede generar clases desbalanceadas y dificultar el entrenamiento de modelos. Además, las menciones de nombres propios, los encabezados de las cartas y las fórmulas de firma pueden actuar como fugas de información, porque permitirían que el algoritmo reconociera al narrador sin aprender rasgos estilísticos reales.

Otro reto se relaciona con el lenguaje literario del siglo XIX. Las herramientas generales de sentimientos pueden interpretar de manera imperfecta la negación, la ironía, el lenguaje figurado, los arcaísmos y las expresiones dependientes del contexto. Por ello, los resultados computacionales deberán presentarse como evidencia complementaria y no como reemplazo de la interpretación literaria.

2.2 Delimitación

El estudio se limitará al texto original en inglés de “Drácula” disponible en dominio público. La unidad de análisis será un fragmento textual asociado con un narrador identificado. Se priorizarán los narradores con una cantidad suficiente de texto para formar conjuntos de entrenamiento y prueba, previsiblemente Jonathan Harker, Mina Harker, John Seward, Lucy Westenra y Abraham Van Helsing.

No se analizarán adaptaciones cinematográficas, traducciones, secuelas ni obras derivadas. Tampoco se intentará atribuir la autoría histórica a personas diferentes de Bram Stoker. El proyecto consiste en clasificar voces ficticias dentro de la novela, no en resolver una controversia de autoría externa.

El periodo de desarrollo comprenderá la obtención y preparación del corpus, el análisis exploratorio, la construcción de modelos, la interpretación de resultados y la documentación reproducible del proyecto. El producto final incluirá código en Python, datos derivados legalmente compartibles, visualizaciones, métricas y un repositorio público.

2.3 Alcances y limitaciones

El alcance es explicativo y predictivo. Será explicativo porque describirá las características que distinguen a cada voz narrativa, y predictivo porque evaluará modelos capaces de asignar una etiqueta de narrador a fragmentos no vistos.

Entre las limitaciones previstas se encuentran el tamaño reducido del corpus, el desbalance de clases, la dependencia entre fragmentos cercanos, la posible influencia del tema sobre el estilo y la dificultad de separar completamente la voz del personaje de la intervención editorial del autor. Para reducir el optimismo en las métricas, la división de datos se realizará por bloques o documentos completos, evitando que fragmentos casi contiguos aparezcan simultáneamente en entrenamiento y prueba.

CAPÍTULO 3

JUSTIFICACIÓN

La investigación es pertinente para la Ciencia de Datos porque integra adquisición y estructuración de datos no tabulares, limpieza textual, ingeniería de características, aprendizaje automático, validación, explicabilidad y visualización. El texto literario se convierte en una fuente de datos compleja cuyo análisis exige decisiones técnicas reproducibles.

Su relevancia académica radica en vincular métodos cuantitativos con una obra de mucha importancia cultural. La estructura documental de “Drácula” proporciona etiquetas narrativas relativamente claras y permite desarrollar un caso de estudio comprensible tanto para especialistas en datos como para lectores interesados en literatura.

La propuesta también posee valor metodológico. En lugar de limitarse a generar nubes de palabras, plantea una tarea verificable mediante métricas: la clasificación del narrador. Esta tarea permite comparar representaciones, algoritmos y estrategias de validación, además de analizar errores mediante matrices de confusión y técnicas de importancia de variables.

El uso de una obra de dominio público favorece la reproducibilidad. El corpus base puede obtenerse legalmente y el código podrá publicarse en GitHub junto con instrucciones para replicar el procesamiento. La disponibilidad pública del repositorio facilitará la revisión del proyecto y su posible extensión a otras novelas epistolares o góticas.

Finalmente, el tema responde a una motivación interdisciplinaria: demostrar que la literatura puede ser abordada con rigor computacional sin reducirla a simples conteos. La interpretación de los resultados se mantendrá conectada con la forma narrativa, los personajes y las limitaciones semánticas de los métodos.

CAPÍTULO 4

FORMULACIÓN DE OBJETIVOS

Objetivo General

Desarrollar y evaluar un sistema de procesamiento de lenguaje natural y aprendizaje automático para caracterizar y clasificar las voces narrativas principales de “Drácula” de Bram Stoker a partir de rasgos léxicos, estilométricos y emocionales.

1.4 Objetivos Específicos

1. Obtener, depurar y estructurar el texto de Drácula en un corpus de fragmentos etiquetados por narrador.
2. Realizar un análisis exploratorio de la distribución de palabras, longitud de fragmentos, riqueza léxica, puntuación y equilibrio entre clases.
3. Construir representaciones textuales mediante TF-IDF de palabras y caracteres, así como un conjunto de variables estilométricas.
4. Estimar sentimientos y emociones por fragmento y narrador, documentando las limitaciones del enfoque léxico.
5. Entrenar y comparar modelos de clasificación, incluyendo Naive Bayes, regresión logística, máquinas de soporte vectorial y un modelo basado en árboles.
6. Evaluar los modelos mediante validación apropiada, accuracy balanceada, macro F1, precisión, exhaustividad y matrices de confusión.
7. Interpretar las variables más influyentes y analizar los errores de clasificación desde una perspectiva computacional y literaria.
8. Publicar un repositorio reproducible con código comentado, documentación, resultados y el reporte de investigación.

CAPÍTULO 5

MARCO TEÓRICO

5.1 Humanidades digitales y análisis literario computacional

Las humanidades digitales reúnen enfoques que utilizan herramientas computacionales para estudiar objetos culturales. En literatura, estos enfoques incluyen análisis de frecuencia, redes de personajes, modelado de temas, estilometría y análisis de sentimientos. Su utilidad principal consiste en ampliar la escala y sistematizar observaciones, aunque los resultados requieren interpretación contextual.

El análisis de sentimientos aplicado a literatura debe utilizarse con cautela. Los textos narrativos contienen ambigüedad, cambios de focalización y recursos retóricos que no siempre son captados por herramientas diseñadas para reseñas o redes sociales. Una revisión crítica reciente señala que la validez de estos métodos depende de la pregunta, el corpus, el modelo y la interpretación de los resultados. (Rebora, 2023)

5.2 Procesamiento de lenguaje natural

El procesamiento de lenguaje natural comprende técnicas para representar, analizar y modelar lenguaje humano mediante computadoras. En este proyecto se utilizarán procedimientos como segmentación, tokenización, normalización, eliminación selectiva de elementos editoriales y vectorización.

La representación TF-IDF pondera los términos según su frecuencia dentro de un documento y su rareza en el corpus. Para clasificación estilométrica también son útiles los n-gramas de caracteres, porque capturan patrones de ortografía, puntuación, contracciones y terminaciones sin depender completamente del significado (Rebora, 2023).

5.3 Estilometría y atribución de autoría

La estilometría es el estudio cuantitativo del estilo. Sus variables pueden agruparse en rasgos léxicos, sintácticos, estructurales, de puntuación y basados en n-gramas. Aunque suele emplearse para atribuir textos a autores reales, sus principios pueden adaptarse al reconocimiento de narradores ficticios.

Eder, Rybicki y Kestemont (2016) describen herramientas de estilometría computacional basadas en frecuencias de palabras y medidas de distancia. Estudios de revisión sobre atribución de autoría destacan que el desempeño depende de la longitud de los textos, el número de clases, el género, el dominio temático, la representación y el protocolo de evaluación (He, Yan, Li, & Liu, 2024).

5.4 Análisis de sentimiento y emociones

El análisis de sentimientos busca estimar orientación positiva o negativa, mientras que el análisis de emociones asigna categorías más específicas. El NRC Emotion Lexicon relaciona palabras con ocho emociones: ira, miedo, anticipación, confianza, sorpresa, tristeza, alegría y disgusto, además de polaridad positiva y negativa (Mohammad & Turney, 2013).

En esta investigación, las emociones se calcularán como proporciones normalizadas por la longitud del fragmento. Estos resultados servirán para describir tendencias y como variables adicionales en modelos experimentales. No se asumirán como mediciones psicológicas directas de los personajes.

5.5 Aprendizaje automático para clasificación de textos

La clasificación supervisada aprende una función a partir de ejemplos etiquetados. En clasificación textual, los modelos lineales suelen ofrecer resultados competitivos cuando se combinan con vectores dispersos de alta dimensión. La regresión logística y las máquinas de soporte vectorial permiten construir líneas base sólidas e interpretar coeficientes asociados con términos o n-gramas.

La evaluación no debe limitarse a accuracy cuando existen clases desbalanceadas. Por ello se considerarán macro F1, precisión y exhaustividad por clase, accuracy balanceada y matrices de confusión. La macro F1 asigna el mismo peso a cada narrador y evita que la clase mayoritaria domine la evaluación.

5.6 La estructura narrativa de Drácula

“Drácula” se presenta como una colección de documentos. Los personajes registran acontecimientos desde posiciones distintas y en momentos diferentes. La alternancia de narradores contribuye a construir suspenso, distribuir información y contrastar interpretaciones de los sucesos.

Esta forma narrativa facilita la creación de etiquetas, pero también genera dependencias: un personaje puede citar cartas de otro, copiar documentos o describir eventos comunes. Por tanto, el modelo podría aprender vocabulario temático en lugar de estilo. Para investigar este riesgo se compararán modelos con y sin nombres propios, y se analizará la importancia de las características.

CAPÍTULO 6

METODOLOGÍA

6.1 Enfoque y diseño

La investigación tendrá un enfoque cuantitativo, aplicado y reproducible. Se desarrollará como un estudio de clasificación multiclase con análisis exploratorio e interpretación de modelos. El diseño será no experimental, porque se analizará un texto existente sin manipular sus condiciones de producción.

6.2 Fuente de datos y construcción del corpus

El texto base se obtendrá de *Project Gutenberg*, que ofrece una edición digital de dominio público de “Drácula”. Se conservará una copia del texto original y se generará una versión procesada mediante scripts, de modo que cada transformación pueda reproducirse.

Los encabezados de diarios, cartas y documentos se usarán para determinar el narrador y después se retirarán del texto utilizado por los modelos. La unidad inicial será cada entrada documental; cuando una entrada sea demasiado extensa, se dividirá en fragmentos de longitud comparable, procurando no cortar oraciones.

6.3 Variables

Variable	Tipo	Descripción	Uso
narrador	Categórica	Personaje al que se atribuye el fragmento	Variable objetivo
texto_limpio	Texto	Fragmento sin encabezados ni firmas reveladoras	Vectorización
num_palabras	Numérica	Cantidad de palabras	Control y análisis
longitud_oracion	Numérica	Promedio de palabras por oración	Rasgo estilométrico
riqueza_lexica	Numérica	Relación entre vocabulario y tokens	Rasgo estilométrico
puntuacion	Numérica	Frecuencias normalizadas de signos	Rasgo estilométrico
emociones_nrc	Numérica	Proporciones de ocho emociones y dos polaridades	Descripción y modelo

tfidf	Vector	N-gramas de palabras o caracteres ponderados	Predictores principales
-------	--------	--	-------------------------

6.4 Preprocesamiento

1. Eliminar el encabezado y el pie editorial de Project Gutenberg.
2. Detectar capítulos, fechas, tipos de documento y narradores.
3. Retirar nombres del narrador en encabezados, firmas y fórmulas explícitas que generen fuga de información.
4. Normalizar espacios y caracteres, conservando la puntuación para los experimentos estilométricos.
5. Segmentar entradas extensas en fragmentos de aproximadamente 300 a 600 palabras.
6. Asignar un identificador de documento de origen para realizar divisiones agrupadas.
7. Revisar manualmente una muestra de etiquetas y registrar decisiones ambiguas.

6.5 Análisis exploratorio

Se calcularán frecuencias por narrador, distribución de longitudes, vocabulario, palabras funcionales, signos de puntuación y emociones. Se visualizarán las diferencias mediante diagramas de barras, cajas, mapas de calor y proyecciones bidimensionales exploratorias.

6.6 Modelado

Modelo	Representación	Propósito
Clase mayoritaria	Sin variables	Línea base mínima
Naive Bayes multinomial	TF-IDF de palabras	Modelo probabilístico de referencia
Regresión logística	TF-IDF y rasgos escalados	Modelo lineal interpretable
SVM lineal	TF-IDF de palabras/caracteres	Modelo competitivo para alta dimensión
Random Forest o Gradient Boosting	Rasgos estilométricos y emociones	Comparación no lineal

6.7 Validación y métricas

La separación de entrenamiento y prueba se realizará agrupando por entrada o documento de origen. De esta manera, fragmentos procedentes de una misma entrada no quedarán en ambos conjuntos. Dentro del

entrenamiento se aplicará validación cruzada agrupada para seleccionar hiperparámetros.

Métrica	Interpretación
Accuracy balanceada	Promedio de la sensibilidad obtenida en cada clase
Macro F1	Promedio del F1 de todos los narradores con igual peso
Precisión por clase	Proporción de predicciones de un narrador que fueron correctas
Exhaustividad por clase	Proporción de fragmentos reales de un narrador detectados
Matriz de confusión	Patrones de error entre pares de narradores

6.8 Interpretabilidad y análisis de errores

Para los modelos lineales se examinarán los coeficientes con mayor peso por narrador. En modelos basados en árboles podrán emplearse importancias por permutación o valores SHAP, siempre que su uso sea metodológicamente adecuado. Los fragmentos mal clasificados se revisarán para determinar si contienen citas, estilo indirecto, temas compartidos, poca longitud o etiquetas ambiguas.

6.9 Herramientas y reproducibilidad

El análisis se desarrollará en Python mediante pandas, NumPy, NLTK o spaCy, scikit-learn, matplotlib y NetworkX cuando resulte necesario. El repositorio incluirá un archivo README, entorno o lista de dependencias, notebooks ordenados, scripts reutilizables, datos derivados y una licencia compatible con los materiales.

CAPÍTULO 7

RESULTADOS Y CONCLUSIONES

7.1 Resultados esperados

Debido a que el presente documento corresponde a un borrador inicial, todavía no se reportan métricas experimentales. Se espera obtener un corpus documentado de voces narrativas, una comparación reproducible de modelos y un conjunto de visualizaciones que describan las diferencias estilísticas y emocionales entre narradores.

Se prevé que los n-gramas de caracteres y las palabras funcionales sean especialmente útiles porque capturan hábitos de puntuación, ortografía y construcción sin depender exclusivamente del tema. También se espera que los narradores con mayor cantidad de texto alcancen mejores resultados que aquellos con pocos ejemplos.

Las matrices de confusión permitirán identificar voces similares. Dichas confusiones no se interpretarán únicamente como fallas del algoritmo: pueden señalar convergencias estilísticas, documentos copiados, pasajes citados o restricciones propias de la construcción literaria.

7.2 Conclusiones preliminares

La propuesta es viable para una tesina de Maestría en Ciencia de Datos porque plantea una pregunta medible, dispone de una fuente de datos legalmente accesible y permite integrar análisis de texto, aprendizaje automático, validación e interpretabilidad.

La principal contribución esperada será un estudio reproducible sobre identificación de narradores ficticiales en una novela epistolar. Su valor no dependerá únicamente de alcanzar una alta exactitud, sino de explicar qué aprende el modelo, cuáles son sus errores y cómo se relacionan esos hallazgos con la estructura de Drácula.

El alcance deberá mantenerse controlado. La clasificación de narradores será el eje central; el análisis emocional funcionará como componente descriptivo complementario. Esta delimitación evita que el proyecto se convierta en una colección de técnicas sin una pregunta unificadora.

ANEXOS

REFERENCIAS

- Eder, M., Rybicki, J., & Kestemont, M. (2016). Stylometry with R: A package for computational text analysis. *The R Journal*, 107-121.
- He, X., Yan, X., Li, Y., & Liu, Y. (2024). Authorship attribution methods, challenges, and future research directions: A comprehensive survey. *Information*, 131.
- Mohammad, S., & Turney, P. (2013). Crowdsourcing a word-emotion association lexicon. *Computational Intelligence*, 436-465.
- Moyano Moreno, I. (1 de 12 de 2023). *Universidad de Cádiz*. Obtenido de La estilometría como técnica de análisis lingüístico-cuantitativo: a propósito del uso terminológico de estilo: <https://rodin.uca.es/handle/10498/31901>
- Rebora, S. (2023). Sentiment analysis in literary studies: A critical survey. *Digital Humanities Quarterly*, 17.
- Stoker, B. (1897). *Dracula*. Archibald Constable and Company.
- Stoker, B. (24 de Septiembre de 2025). *Project Gutenberg*. Obtenido de Dracula (Project Gutenberg eBook No. 345): <https://www.gutenberg.org/ebooks/345>